



به نام خدا



دانشگاه تهران
دانشکده مهندسی برق و کامپیوتر
مدل‌های مولد عمیق

تمرین سوم

نام و نام خانوادگی	سید نوید هاشمی
شماره دانشجویی	810101549
تاریخ ارسال گزارش	1404/10/2

فهرست

3.....	سؤال اول
3.....	بخش اول : سوالات تئوری
3.....	زیربخش اول
3.....	زیربخش دوم
4.....	زیربخش سوم
5.....	بخش دوم : سوالات پیاده سازی
5.....	زیربخش اول : بارگذاری دیتاست و آماده سازی داده
6.....	زیربخش دوم : پیاده سازی معماری و آموزش مدل
7.....	زیربخش سوم : تولید تصویر
9.....	زیربخش چهارم : نويززدایی تصویر نویزی
11.....	سوال دوم
11.....	بخش اول : سوالات تئوری
11.....	زیربخش اول
11.....	زیربخش دوم
12.....	زیربخش سوم
13.....	زیربخش چهارم
14.....	بخش دوم : سوالات پیاده سازی
14.....	زیربخش اول : مدل پایه
17.....	زیربخش دوم : مدل شرطی

سؤال اول

بخش اول : سوالات تئوری

زیربخش اول

برای تولید تصاویر با ویژگی‌های ترکیبی خاص (مانند مرد جوان) و تسهیل فرآیند آموزش، می‌توان از ویژگی ترکیب‌پذیری (Compositionality) یا جمع‌پذیری توابع انرژی استفاده کرد.

در مدل‌های مبتنی بر انرژی، تابع چگالی احتمال به صورت $p(x) \propto e^{-E(x)}$ تعریف می‌شود. بر اساس اصل Product of Experts، اشتراک چندین توزیع احتمال مستقل (مثلاً توزیع چهره‌های مرد و توزیع چهره‌های جوان) معادل جمع کردن توابع انرژی متناظر با آن هاست.

بنابراین، برای آموزش راحت‌تر، به جای آموزش یک مدل پیچیده روی مجموعه داده‌ی خاص و محدود مردان جوان، می‌توانیم در ابتدا یک تابع انرژی مستقل $E_{gender}(x)$ را آموزش دهیم که ویژگی جنسیت (مرد بودن) را یاد بگیرد، سپس یک تابع انرژی مستقل دیگر $E_{age}(x)$ را آموزش دهیم که ویژگی سن (جوان بودن) را یاد بگیرد، در نهایت برای تولید تصویر، از تابع انرژی کل استفاده می‌کنیم که حاصل جمع توابع فوق است:

$$E_{total}(x) = E_{gender}(x) + E_{age}(x)$$

این روش آموزش را ساده‌تر می‌کند زیرا مدل‌ها می‌توانند به صورت جداگانه و روی مجموعه داده‌های مستقل (که جمع آوری آن‌ها نسبت به تصاویر مردهای جوان آسان‌تر است) آموزش ببینند و در زمان Inference با هم ترکیب شوند.

زیربخش دوم

• Rejection Sampling

روش Rejection Sampling تکنیکی برای تولید نمونه از یک توزیع هدف پیچیده $P(x)$ است که نمونه برداری مستقیم از آن دشوار است. در این روش از یک توزیع پیشنهادی (Proposal Distribution) ساده‌تر مانند $Q(x)$ استفاده می‌شود که نمونه برداری از آن آسان است و باید شرط $M \cdot Q(x) \geq P(x)$ برای تمامی x ها و یک ثابت $M < \infty$ برقرار باشد.

مراحل الگوریتم به شرح زیر است:

1. یک نمونه x از توزیع $Q(x)$ تولید می‌کنیم.
2. یک عدد تصادفی u از توزیع یکنواخت $U[0, 1]$ تولید می‌کنیم.
3. اگر $u < \frac{P(x)}{M \cdot Q(x)}$ باشد، نمونه x را می‌پذیریم. (Accept)
4. در غیر این صورت، نمونه را رد کرده (Reject) و به مرحله ۱ باز می‌گردیم.

• محاسبه Optimal Acceptance Rate

برای محاسبه نرخ پذیرش، ابتدا باید مقدار ثابت M را پیدا کنیم. M برابر با مقدار بیشینه نسبت چگالی احتمال هدف به چگالی پیشنهادی است. فرض می کنیم داده های MNIST بردار هایی با ابعاد $D = 28 \times 28 = 784$ هستند. دو توزیع احتمال نرمال چند متغیره هم مرکز داریم:

$$P(x) = \frac{1}{(2\pi\sigma_p^2)^{D/2}} \exp\left(-\frac{\|x - \mu\|^2}{2\sigma_p^2}\right)$$

$$Q(x) = \frac{1}{(2\pi\sigma_q^2)^{D/2}} \exp\left(-\frac{\|x - \mu\|^2}{2\sigma_q^2}\right)$$

اکنون نسبت این دو عبارت را محاسبه می کنیم:

$$\begin{aligned} \frac{P(x)}{Q(x)} &= \frac{(2\pi\sigma_q^2)^{D/2}}{(2\pi\sigma_p^2)^{D/2}} \exp\left(-\frac{\|x - \mu\|^2}{2} \left(\frac{1}{\sigma_p^2} - \frac{1}{\sigma_q^2}\right)\right) \\ &= \left(\frac{\sigma_q}{\sigma_p}\right)^D \exp\left(-\frac{\|x - \mu\|^2}{2} \left(\frac{\sigma_q^2 - \sigma_p^2}{\sigma_p^2 \sigma_q^2}\right)\right) \end{aligned}$$

از آنجا که طبق صورت سوال $\sigma_p = 1.01\sigma_q$ است، پس $\sigma_q > \sigma_p$ و عبارت داخل پرانتز در توان نمایی مثبت است. در نتیجه کل توان منفی خواهد بود. برای پیدا کردن M (بیشینه این نسبت)، باید توان نمایی صفر شود (چرا که ماکسیمم تابع e^{-y} برای $y \geq 0$ در $y = 0$ رخ می دهد). این اتفاق در $x = \mu$ می افتد. بنابراین مقدار M برابر است با:

$$M = \max_x \frac{P(x)}{Q(x)} = \left(\frac{\sigma_q}{\sigma_p}\right)^D = (1.01)^{784}$$

$$Acceptance Rate = \frac{1}{M} \approx \frac{1}{2463} \approx 4.06 \times 10^{-4}$$

مشاهده می شود با وجود اینکه انحراف معیار ها تنها ۱ درصد اختلاف دارند، به دلیل ابعاد بالای داده های MNIST ($D=784$)، نرخ پذیرش بسیار پایین (حدود ۰.۰۴٪) خواهد بود که این مسئله نشان دهنده ناکارآمدی روش Rejection Sampling در ابعاد بالا است.

زیربخش سوم

(الف)

با توجه به رابطه، هدف فرآیند آموزش ماکسیمم کردن احتمال داده های آموزشی است. گرادیان شامل دو ترم با اثرات متضاد است؛ ترم $\nabla_{\theta} f_{\theta}(x_{train})$ باعث می شود پارامترها به سمتی حرکت کنند که مقدار تابع f (که معیاری از سازگاری یا

Negative Energy است) برای داده‌های آموزشی افزایش یابد و ترم $-E[\nabla_{\theta} f_{\theta}(x_{sample})]$ باعث می‌شود پارامترها به سمتی بروند که مقدار تابع f برای نمونه‌های تولید شده توسط مدل فعلی (Fake Samples) کاهش یابد. در نتیجه، آموزش سعی دارد شکاف بین داده‌های واقعی و داده‌های مصنوعی را با بالا بردن امتیاز داده‌های واقعی و پایین آوردن امتیاز داده‌های مدل (در نواحی‌ای که مدل به اشتباه احتمال بالا داده است) افزایش دهد.

(ب)

محاسبه ترم دوم گرادینان نیازمند محاسبه امید ریاضی روی توزیع مدل (p_{θ}) است. برای بدست آوردن نمونه‌هایی که واقعا از توزیع p_{θ} باشند، نیاز به روش‌های نمونه‌برداری MCMC (مانند Langevin Dynamics) داریم که باید تا زمان رسیدن به تعادل اجرا شوند. این فرآیند از نظر محاسباتی بسیار سنگین و زمان‌بر است، زیرا برای هر گام از آپدیت گرادینان، باید زنجیره مارکوف برای دفعات زیادی اجرا شود.

روش CD برای حل این مشکل، فرآیند نمونه‌برداری را ساده‌سازی می‌کند. در این روش، به جای شروع زنجیره MCMC از نویز تصادفی و انتظار برای رسیدن به تعادل کامل، زنجیره از روی داده‌های آموزشی مقداردهی اولیه می‌شود و تنها به تعداد محدودی گام اجرا می‌شود. این تقریب باعث می‌شود که هزینه محاسباتی به شدت کاهش یابد و آموزش مدل ممکن شود.

بخش دوم : سوالات پیاده سازی

زیربخش اول : بارگذاری دیتاست و آماده سازی داده

در این بخش، دیتاست MNIST با موفقیت بارگذاری و به بازه $[0,1]$ ، normalize شد. در ادامه تصاویر تصادفی از داده‌های train و test نمایش داده شده‌اند.




Figure 1- چند تصویر تصادفی از داده‌های train

Random Test Images




Figure 2 - چند تصویر تصادفی از داده های test

زیربخش دوم : پیاده سازی معماری و آموزش مدل

Generated Samples - Epoch 0



Figure 3 - تعدادی تصویر تولید شده در ابتدای آموزش (اپیاک 0)

Generated Samples - Epoch 5




Figure 4 - تعدادی تصویر تولید شده در وسط آموزش (اپیاک 5)

Generated Samples - Epoch 9




Figure 5 - تعدادی تصویر ایجاد شده در انتهای آموزش (اپیاک 9)




Figure 6 - بررسی پایداری داده‌های آموزشی تحت Langevin Dynamic (ردیف بالا: تصاویر اصلی انتخاب شده از مجموعه داده آموزشی. ردیف پایین: خروجی مدل پس از اعمال الگوریتم Langevin Sampling با نقطه شروع تصاویر ردیف بالا.)

همان‌طور که در تصویر Figure 6 مشاهده می‌شود، خروجی‌های الگوریتم شباهت بسیار زیادی به ورودی‌های اصلی دارند و تغییرات فاحشی در ساختار ارقام ایجاد نشده است که نشان می‌دهد مدل به درستی یاد گرفته است که به داده‌های واقعی، انرژی کمی اختصاص دهد. همچنین می‌توان گفت که اگر مدل به خوبی آموزش ندیده بود، اعمال Langevin روی داده واقعی ممکن بود باعث تخریب تصویر یا تبدیل آن به نویز شود. حفظ ساختار تصویر نشان می‌دهد که منیفولد یاد گرفته شده توسط مدل با توزیع واقعی داده‌ها منطبق است (تغییرات جزئی مشاهده شده ناشی از تلاش مدل برای تمیزتر کردن یا حرکت دادن داده به سمت مرکز چگالی توزیع یاد گرفته شده است).

زیربخش سوم : تولید تصویر




Figure 7 - ارزیابی پایداری مدل روی داده‌های آموزشی. (ردیف بالا: تصاویر اصلی انتخاب شده از مجموعه داده Train ردیف پایین: خروجی مدل پس از اعمال الگوریتم Langevin Dynamics روی تصاویر ردیف بالا.)

در این قسمت، مشاهده می‌شود که برخی از تصاویر پس از طی کردن مراحل نمونه‌برداری Langevin، تغییر ماهیت داده‌اند مثلاً یک عدد به عدد دیگر تبدیل شده یا جزئیات آن حذف شده است. این پدیده به چند دلیل نظری در مدل‌های مبتنی بر انرژی (EBM) رخ می‌دهد که در ادامه برخی از آنها را به اختصار توضیح می‌دهم:

۱. عدم تطابق فاز آموزش و تست

مدل ما با روش Contrastive Divergence و با تعداد گام‌های کم (مثلاً $K = 1$ یا $K = 10$) آموزش دیده است. این یعنی مدل یاد گرفته است که انرژی را فقط در همسایگی بسیار نزدیک داده‌های واقعی پایین بیاورد. اما در زمان تست، ما الگوریتم Langevin را برای تعداد گام‌های بسیار بیشتری (مثلاً ۱۰۰ گام) اجرا می‌کنیم. چون مدل مسیرهای طولانی را در آموزش ندیده است، نمونه‌بردار ممکن است از Energy Valley مربوط به عدد اصلی خارج شده و به سمت نواحی ناشناخته یا دره‌های دیگر (اعداد دیگر) حرکت کند.

۲. هموار شدن سطح انرژی

شبکه‌های عصبی تمایل دارند توابع هموار را یاد بگیرند. ممکن است مدل به جای یادگیری یک قله‌ی تیز دقیقاً روی تصویر عدد "۵" خاص، یک دشت وسیع با انرژی پایین یاد گرفته باشد که شامل انواع شکل‌های عدد ۵ و حتی اعداد شبیه به آن (مثل ۳ یا ۶) باشد. نویز موجود در فرآیند Langevin می‌تواند داده را در این دشت جابجا کند و باعث تغییر شکل ظاهری آن شود.


۳. پرش بین مدها

اگر سدهای انرژی (Energy Barriers) بین دو عدد (مثلاً بین ۱ و ۷) به اندازه کافی توسط مدل مرتفع نشده باشند، نویز نمونه‌برداری می‌تواند sampler را از حوضه جذب عدد ۱ به حوضه جذب عدد ۷ پرتاب کند. این اتفاق نشان می‌دهد که مدل هنوز نتوانسته مرزهای دقیق بین کلاس‌های مختلف را به طور کامل و قطعی جدا کند.

با توجه به موارد گفته شده، تفاوت تصاویر خروجی با ورودی نشان می‌دهد که اگرچه مدل توزیع کلی ارقام MNIST را یاد گرفته است (چون خروجی‌ها شبیه عدد هستند)، اما هنوز به یک مدل پایدار که داده‌های آموزشی دقیقاً منطبق بر مینیمم‌های مطلق انرژی باشند، نرسیده است.


زیربخش چهارم : نویزدایی تصویر نویزی

Denoising (Noise $\sigma = 0.2$)
Top: Real | Middle: Noisy | Bottom: Denoised



8 Figure - ارزیابی عملکرد مدل در نویزدایی با سطح نویز 0.2

Denoising (Noise $\sigma = 0.4$)
Top: Real | Middle: Noisy | Bottom: Denoised



9 Figure - ارزیابی عملکرد مدل در نویزدایی با سطح نویز 0.4




Figure 10 - ارزیابی عملکرد مدل در نویزدایی با سطح نویز 0.6

در این قسمت، توانایی مدل در بازیابی تصاویر اصلی از روی تصاویر نویزی با سه سطح شدت نویز (0.2، 0.4 و 0.6) مورد بررسی قرار گرفت. نتایج بدست آمده، رفتارهای متفاوتی را نشان می‌دهند که در ادامه تحلیل می‌شوند:

۱. سطح نویز کم ($\sigma = 0.2$) موفقیت آمیز

در این سطح، نویز اضافه شده کم است و تصویر نویزی همچنان در نزدیکی تصویر اصلی روی منیفولد داده‌ها قرار دارد. به بیان دقیق‌تر، نقطه نویزی هنوز در حوضه جذب مینیمم انرژی مربوط به عدد اصلی قرار دارد. بنابراین، گرادیان انرژی به درستی جهت به سمت تصویر اصلی را نشان می‌دهد و الگوریتم Langevin موفق می‌شود تصویر را تمیز کرده و ساختار دقیق عدد را بازیابی کند.

۲. سطح نویز متوسط ($\sigma = 0.4$) موفقیت نسبی با افت کیفیت

در این حالت، نویز بیشتر شده و تصویر از منیفولد اصلی دورتر شده است. مدل همچنان تلاش می‌کند ساختاری شبیه به عدد بسازد، اما همانطور که در Figure 9 مشاهده می‌شود، ممکن است در بازیابی جزئیات دقیق (مثل لبه‌های تیز) دچار مشکل شود. همچنین با اینکه در Figure 9 قابل مشاهده نیست، در برخی موارد ممکن است تصویر بازیابی شده کمی تار باشد که ناشی از عدم قطعیت مدل در آن ناحیه از فضای انرژی است.

۳. سطح نویز زیاد ($\sigma = 0.6$) شکست و Mode Hopping

در این سطح، نتایج در بسیاری از موارد نامطلوب هستند. همانطور که در Figure 10 مشاهده می‌شود، تصویر بازیابی شده شباهتی به تصویر اصلی ندارد یا تبدیل به عدد دیگری شده است. شدت نویز آنقدر زیاد است که داده را از Energy Valley مربوط به عدد اصلی به بیرون پرتاب می‌کند و آن را وارد دره انرژی یک عدد دیگر یا یک مینیمم محلی کاذب (Spurious Local Minimum) می‌کند. همچنین مدل ما با روش Contrastive Divergence آموزش دیده است

که فقط انرژی را در همسایگی بسیار نزدیک داده‌های آموزشی تنظیم می‌کند. در نقاطی که نویز شدید است و فاصله زیادی با داده‌های واقعی دارد، مدل ممکن است هیچگاه در زمان آموزش دیده نشده باشد، بنابراین گرادیان انرژی در آن نقاط تعریف نشده یا تصادفی است و نمی‌تواند مسیر بازگشت درست را به سمپلر نشان دهد.

پس مشاهده می‌شود که مدل EBM آموزش دیده در این بخش، ساختار محلی منیفولد داده‌ها را یاد گرفته است، اما هنوز یک مدل Robust نیست.

سوال دوم

بخش اول : سوالات تئوری

زیربخش اول

تابع امتیاز به عنوان گرادیان (مشتق جهت دار) لگاریتم تابع چگالی احتمال نسبت به داده‌ی ورودی تعریف می‌شود $(\nabla_x \log P(x))$. به زبان ساده، این بردار به ما می‌گوید که اگر بخواهیم احتمال داده را افزایش دهیم، باید x را در چه جهتی تغییر دهیم. با توجه به این تعریف تابع امتیاز مدل داده شده را حساب می‌کنیم:

$$p_{\theta}(x) = \frac{e^{-E_{\theta}(x)}}{Z(\theta)}$$

$$\log(p_{\theta}(x)) = \log\left(\frac{e^{-E_{\theta}(x)}}{Z(\theta)}\right) = \log(e^{-E_{\theta}(x)}) - \log(Z(\theta))$$

$$\nabla_x \log(p_{\theta}(x)) = \nabla_x (\log(e^{-E_{\theta}(x)}) - \log(Z(\theta))) = \nabla_x \log(e^{-E_{\theta}(x)}) - \nabla_x \log(Z(\theta))$$

از آنجا که $Z(\theta)$ نسبت به x ثابت است، گرادیان آن نسبت به x ، 0 است و خواهیم داشت:

$$\nabla_x \log(p_{\theta}(x)) = \nabla_x \log(e^{-E_{\theta}(x)}) = \nabla_x (-E_{\theta}(x))$$

این رابطه نشان می‌دهد که تابع امتیاز این مدل، مستقل از تابع پارتیشن $Z(\theta)$ است؛ حال چون Z حذف می‌شود، ما می‌توانیم بدون نیاز به محاسبه انتگرال‌های سخت یا استفاده از روش‌های تقریبی پیچیده (مثل MCMC در روش Contrastive Divergence)، مدل را آموزش دهیم. این کار سرعت و پایداری آموزش را بسیار بالا می‌برد.

زیربخش دوم

تابع هزینه اصلی Score Matching به صورت زیر تعریف می‌شود:

$$J(\theta) = E_{p_{data}} \left[\frac{1}{2} \|s_{\theta}(x)\|^2 + \text{tr}(\nabla_x s_{\theta}(x)) \right]$$

ترم دوم، یعنی trace ماتریس ژاکوبین تابع امتیاز، نیازمند محاسبه مشتقات جزئی تمام ابعاد خروجی $s_{\theta}(x)$ نسبت به تمام ابعاد ورودی x است. برای داده‌هایی با ابعاد بالا مانند تصاویر، اگر تعداد پیکسل‌ها D باشد، محاسبه این ترم نیازمند انجام D مرتبه عملیات Backpropagation برای هر نمونه داده است. به عنوان مثال برای یک تصویر ساده MNIST با ابعاد $D = 784$ ، هزینه محاسباتی صد ها برابر می‌شود که عملاً آموزش مدل را غیرممکن می‌سازد.

برای حل مشکل محاسباتی فوق، روش DSM پیشنهاد می‌کند که به جای تطبیق مستقیم با score داده‌های واقعی (که نامعلوم است)، داده‌ها را با یک نویز مشخص (که معمولاً گوسی است) مخدوش کنیم و سپس score این توزیع نویز را تخمین بزنیم.

فرض می‌کنیم داده مخدوش شده $\tilde{x}$ از توزیع $q_\sigma(\tilde{x}|x)$ باشد. از آنجا که توزیع نویز را خودمان انتخاب کرده‌ایم (مثلاً توزیع نرمال $\mathcal{N}(\tilde{x}; x, \sigma^2 I)$ ، فرم $\nabla_{\tilde{x}} \log q_\sigma(\tilde{x}|x)$ ساده خواهد بود و برابر با $\frac{x - \tilde{x}}{\sigma^2}$ است. هدف مدل در این روش، یادگیری تابعی است که بتواند این گرادیان ساده را پیش‌بینی کند، که عملاً به معنای یادگیری نحوه حذف نویز از داده است.

تابع هدف DSM به صورت زیر تعریف می‌شود:

$$J_{DSM}(\theta) = E_{x \sim p_{data}, \tilde{x} \sim q_\sigma(\tilde{x}|x)} \left[\frac{1}{2} \|s_\theta(\tilde{x}) - \nabla_{\tilde{x}} \log q_\sigma(\tilde{x}|x)\|^2 \right]$$

اکنون نشان می‌دهیم که کمینه کردن این تابع، معادل کمینه کردن اختلاف score مدل با score واقعی توزیع نویزی شده $q_\sigma(\tilde{x}) = \int q_\sigma(\tilde{x}|x) p_{data}(x) dx$ است. طبق رابطه وینست (Vincent 2011)، گرادیان توزیع marginal برابر با امید ریاضی گرادیان توزیع شرطی است؛ یعنی:

$$\nabla_{\tilde{x}} \log q_\sigma(\tilde{x}) = E_{p(x|\tilde{x})} [\nabla_{\tilde{x}} \log q_\sigma(\tilde{x}|x)]$$

با بسط دادن تابع هزینه DSM و با استفاده از رابطه بالا می‌توان ثابت کرد که:

$$J_{DSM}(\theta) = E_{\tilde{x} \sim q_\sigma(\tilde{x})} \left[\frac{1}{2} \|s_\theta(\tilde{x}) - \nabla_{\tilde{x}} \log q_\sigma(\tilde{x})\|^2 \right] + C$$

که در آن C مقداری ثابت و مستقل از θ است. پس مینیمم کردن تابع هدف DSM معادل مینیمم کردن تابع هدف Score Matching اصلی روی توزیع نویزی شده است.

زیربخش سوم

(الف)

توزیع داده‌ها به صورت $p_{data}(x) = \pi p_1(x) + (1 - \pi) p_2(x)$ است. تابع امتیاز آن به صورت زیر محاسبه خواهد شد:

$$s(x) = \nabla_x \log(p(x)) = \nabla_x \log(\pi p_1(x) + (1 - \pi) p_2(x))$$

فرض کنیم نقطه x در ناحیه A (تکیه گاه p_1) قرار داشته باشد. با توجه به فرض Disjoint Supports، در این ناحیه $p_2(x) = 0$ است پس رابطه بالا بصورت زیر خواهد شد:

$$\begin{aligned} s(x) &= \nabla_x \log(\pi p_1(x)) \\ s(x) &= \nabla_x (\log \pi + \log p_1(x)) \\ s(x) &= 0 + \nabla_x \log p_1(x) \\ s(x) &= \nabla_x \log p_1(x) \end{aligned}$$

همانطور که مشاهده می‌شود، ضریب π که درون یک لگاریتم ثابت قرار گرفته، در اثر مشتق‌گیری حذف می‌شود. همین استدلال برای ناحیه B نیز صادق است. بنابراین، تابع امتیاز واقعی در هر ناحیه، تنها به ساختار موضعی همان توزیع وابسته است و هیچ اطلاعاتی درباره وزن‌های کلی π و $1 - \pi$ که اهمیت نسبی دو توزیع را نشان می‌دهند، حمل نمی‌کند.

(ب)

از آنجا که الگوریتم Langevin Dynamics برای تولید نمونه، تنها از اطلاعات گرادیان (تابع امتیاز) استفاده می‌کند و طبق قسمت (الف)، تابع امتیاز حاوی هیچ اطلاعاتی درباره ضریب وزنی (π) نیست، این الگوریتم هیچ مکانیزمی برای تشخیص اینکه کدام mode احتمال بیشتری دارد در اختیار ندارد.

در واقع وقتی نمونه برداری در یکی از نواحی (مثلا A) قرار می‌گیرد، گرادیان‌ها فقط آن را به سمت قله همان ناحیه هدایت می‌کنند و هیچ نیرویی برای هل دادن نمونه به سمت ناحیه دیگر (حتی اگر ناحیه دیگر وزن بسیار بیشتری داشته باشد) وجود ندارد. از آنجا که تکیه‌گاه‌ها جدا هستند، گرادیان در فضای میانی نیز صفر یا نامشخص است و نمونه‌بردار نمی‌تواند بین مد‌ها جابجا شود. در نتیجه، نسبت نمونه‌های تولید شده از هر ناحیه تنها به نقطه شروع اولیه بستگی دارد و نسبت‌های واقعی توزیع (یعنی π و $1 - \pi$) رعایت نمی‌شوند.

زیربخش چهارم

(الف)

این کار با دو چالش اساس رو به رو است که هر کدام را مختصراً توضیح می‌دهم:

1. فرضیه Manifold

داده‌های واقعی در دنیای واقعی معمولاً روی یک زیر فضای (Manifold) بسیار کم بعد تعبیه شده در فضای اصلی R^D را پوشش نمی‌دهد. در نتیجه، برای اکثر نقاط فضا که خارج از این منی‌فولد قرار دارند، چگالی احتمال $p_{data}(x)$ برابر با صفر است. در این نقاط، لگاریتم احتمال $(\log p(x))$ به سمت $-\infty$ میل می‌کند و تابع امتیاز $(\nabla_x \log p(x))$ تعریف نشده خواهد بود. بنابراین مدل نمی‌تواند گرادیان معنا داری را در این نواحی یاد بگیرد.

2. تخمین نادقیق در نواحی کم چگالی

حتی اگر فرض کنیم چگالی در همه جا دقیقاً صفر نیست، داده‌ها در فضای با ابعاد بالا بسیار پراکنده هستند. در روش Score Matching، مدل تنها در نواحی که داده وجود دارد آموزش می‌بیند و تابع امتیاز را یاد می‌گیرد. اما هنگام تولید تصویر، فرآیند نمونه‌برداری Langevin Dynamics معمولاً از نویز خالص شروع می‌شود که در نواحی کم‌چگالی قرار دارد. چون مدل هیچ داده آموزشی در این نواحی ندیده است، تخمین تابع امتیاز در آنجا بسیار نا دقیق و تصادفی است. این باعث می‌شود که نمونه بردار در ابتدای کار به سمت نادرستی هدایت شود و هرگز نتواند به منی‌فولد داده‌های واقعی همگرا شود.

(ب)

این مقاله برای حل مشکلات ذکر شده در قسمت (الف) دو راهکار ارائه می دهد که هر کدام را مختصراً توضیح می دهیم:

1. اغتشاش نویز چندمقیاسه

در اینجا بجای آموزش مدل روی داده های خام، مدل روی دنباله ای از توزیع های نویزی شده $\{p_{\sigma_i}(x)\}_{i=1}^L$ آموزش می بیند که با افزودن نویزهای گوسی با انحراف معیارهای $\sigma_1 > \sigma_2 > \dots > \sigma_L$ به داده اصلی ایجاد شده اند.

افزودن نویز باعث می شود که تکیه گاه توزیع داده ها گسترش یابد و کل فضای R^D را پوشش دهد. این کار باعث می شود تابع امتیاز در تمام نقاط فضا به خوبی تعریف شود و دیگر مشکل تعریف نشده بودن گرادیان وجود نداشته باشد. همچنین مدل $S_\theta(x, \sigma)$ یاد می گیرد که برای هر سطح نویز، اسکور مناسب را تخمین بزند که فرآیند یادگیری را در نواحی کم چگالی پایدار می کند.

2. Annealed Langevin Dynamics

در این روش نمونه برداری، فرایند نمونه برداری با بزرگترین سطح نویز (σ_1) شروع می شود و تعدادی گام Langevin اجرا می شود. سپس از آخرین نمونه ی بدست آمده به عنوان نقطه شروع برای سطح نویز بعدی استفاده می شود و این روند تا (σ_L) ادامه می یابد.

با این کار، در سطوح نویز بالا، توزیع ها بسیار هموار هستند و مد های جداگانه (که در داده اصلی دور از هم بودند) به یکدیگر متصل می شوند یا همپوشانی پیدا می کنند. این ویژگی به این الگوریتم اجازه می دهد که به راحتی در فضا حرکت کند و در مد های صحیح (با وزن احتمالی درست) قرار گیرد، بدون اینکه در کمینه های محلی گیر کند.

همچنین درباره نقش σ_1 و σ_L باید بگویم که σ_1 باید آنقدر بزرگ باشد که داده ها کل فضا را پوشش دهند و مد های مجزای داده را به هم متصل کند. نقش اصلی آن تسهیل پیمایش فضا و تضمین Mixing صحیح برای نمونه بردار است تا بتواند از هر نقطه تصادفی اولیه، به سمت صحیح هدایت شود. همچنین σ_L تعیین کننده کیفیت بصری نهایی نمونه هاست. پس از اینکه نمونه بردار در مراحل قبلی به ناحیه درست منیفولد رسید، در مرحله آخر، این نویز اعمال شده است. همچنین این مقدار باید به قدری کوچک باشد که اثر نویز روی داده ها برای انسان قابل تشخیص نباشد و نمونه تولید شده بسیار نزدیک به توزیع داده های واقعی باشد.

بخش دوم : سوالات پیاده سازی

زیربخش اول : مدل پایه

3) آموزش و خروجی ها

نمودار تابع هزینه که در Figure 11 قابل مشاهده است، نشان دهنده همگرایی پایدار مدل است. مشاهده می شود که خطا به سرعت در ایپاک های اولیه کاهش یافته و سپس به یک مقدار ثابت همگرا شده است. این کاهش نشان می دهد که شبکه ScoreNet موفق شده است میدان گرادیان لگاریتمی ($\nabla_x \log p(x)$) را برای تمام سطوح نویز (σ_1 تا σ_L) به

درستی تخمین بزند. استفاده از تابع هزینه وزن دار ($\lambda(\sigma) \propto \sigma^2$) باعث شده است که مشارکت سطوح مختلف نویز در خطا متعادل شود و مدل هم روی نویزهای بزرگ (ساختار کلی) و هم نویزهای کوچک (جزئیات) به خوبی آموزش ببیند.




Figure 11 - روند تغییرات تابع هزینه (Weighted Fisher Divergence) بر حسب اپاک در طول فرآیند آموزش مدل NCSN.

در ادامه در Figure 12، تصاویر ارقام تولید شده قابل مشاهده است. این تصاویر نشان می دهد تصاویر NCSN دارای لبه های تیز و کنتراست بالا هستند که این به دلیل ماهیت الگوریتم Langevin است که در گام های پایانی (با σ کوچک) داده را دقیقاً به سمت منیفولد داده های واقعی هل می دهد. همچنین در این خروجی، تنوع خوبی از ارقام مختلف (۰ تا ۹) با سبک های نوشتاری متفاوت دیده می شود که نشان دهنده عدم رخداد پدیده Mode Collapse است. مدل توانسته است توزیع چندوجهی (Multi-modal) دیتاست MNIST را به خوبی پوشش دهد.

اما مورد مهم دیگری نیز هست که باید به آن اشاره کنم. در گرید تولید شده، مشاهده می شود که برخی از نمونه ها ساختار واضحی ندارند یا شبیه ترکیبی از دو عدد هستند. این پدیده ناشی از چند عامل ذاتی در مدل های Score-Based و روش نمونه برداری Langevin است که بطور خلاصه عبارتند از:

۱. نواحی گذار در منیفولد داده

مدل های مولد سعی می کنند یک توزیع احتمال پیوسته را روی فضای داده ها یاد بگیرند. در فضای برداری، بین کلاستر های دو عدد، مثلاً عدد ۳ و کلاستر عدد ۸، نواحی گذری وجود دارد. وقتی نمونه برداری از نویز تصادفی شروع می شود، سمپلر ممکن است در این نواحی مرزی متوقف شود. در نتیجه، خروجی تصویری است که ویژگی های هر دو عدد را دارد اما شبیه هیچ کدام به طور کامل نیست. این نشان می دهد مدل ما پیوستگی فضای داده را یاد گرفته است، نه فقط حفظ کردن تصاویر خاص.

۲. همگرایی ناقص

الگوریتم Annealed Langevin Dynamics به صورت تئوری تنها زمانی به توزیع دقیق همگرا می شود که تعداد گام ها (T) به سمت بی نهایت و اندازه گام (ϵ) به سمت صفر برود. در عمل، ما از تعداد گام های محدود استفاده می کنیم. برای برخی از نقاط شروع، این تعداد گام کافی نیست تا سمپلر بتواند مسیر طولانی تا رسیدن به مرکز یک Mode تمیز را طی کند پس در میان راه متوقف می شود.

۳. مینیم‌های محلی کاذب

score function که شبکه عصبی یاد گرفته است، یک تقریب از گرادیان واقعی است. این تقریب ممکن است در نواحی کم‌چگالی دارای خطاهایی باشد که باعث ایجاد اصطلاحاً چاه‌های جاذبه کاذب شود. سمپلر ممکن است در این نقاط گیر کند و تصویری تولید کند که از نظر مدل موجه است، اما برای انسان معنای عدد خاصی ندارد.

Final Generated Samples (NCSN)



Figure 12 - شبکه ۱۶ تایی از تصاویر تولید شده نهایی توسط مدل NCSN با استفاده از الگوریتم Annealed Langevin Dynamics (شروع از نویز Uniform)

در ادامه در Figure 13 مکانیزم اصلی مدل‌های NCSN را به تصویر کشیده شده و فرضیه منیفولد را تایید می‌کند؛ همانطور که مشاهده می‌شود، در فاز ابتدایی (نویزهای بزرگ - سمت چپ)، گرادیان‌ها فقط جهت کلی تراکم داده را نشان می‌دهند. مشاهده می‌شود که در این مراحل، نویز خالص کم کم تبدیل به لکه‌های مبهم می‌شود. این مرحله معادل پیدا کردن مکان کلی منیفولد داده‌ها در فضای برداری است.

در ادامه در فاز میانی (نویزهای متوسط) با کاهش σ این لکه‌ها فرم مشخص‌تری به خود می‌گیرند و شباهت آن‌ها به ارقام خاص (مثلاً ساختار دو حلقه برای ۸) نمایان می‌شود.

و در نهایت در فاز پایانی (نویزهای کوچک - سمت راست) مدل فقط روی جزئیات ریز کار می‌کند. لبه‌ها تمیز می‌شوند و نویزهای باقی‌مانده حذف می‌گردند.

این فرآیند نویززدایی تدریجی دلیل اصلی موفقیت NCNC در تولید تصاویر باکیفیت است، زیرا مشکل گیر کردن در مینیم‌های محلی که در Langevin معمولی رخ می‌دهد را با استفاده از این مفهوم حل کرده است.




Figure 13 - مصورسازی فرآیند تولید تصویر از نویز خالص تا عدد نهایی برای ۳ نمونه تصادفی. (حرکت از σ_{begin} در سمت چپ به σ_{end} در سمت راست).

زیربخش دوم: مدل شرطی

نمودار تابع هزینه که در Figure 14 قابل مشاهده است، روند همگرایی مدل شرطی را نشان می‌دهد. مشابه مدل پایه، تابع هزینه با شیب مناسبی کاهش یافته و به پایداری رسیده است. نکته قابل توجه این است که با وجود اضافه شدن ورودی‌های جدید (لیبل‌های کلاس)، مدل توانسته است به خوبی خود را با داده‌ها تطبیق دهد و میدان گرادینت شرطی $\nabla_x \log p(x|y)$ را یاد بگیرد. همچنین ثبات نمودار در ایپاک‌های پایانی نشان‌دهنده تنظیم مناسب نرخ یادگیری و پارامترهای شبکه است.




Figure 14 - منحنی تغییرات تابع هزینه (Weighted DSM Loss) در طول آموزش مدل شرطی. (Conditional NCSN)



Figure 15 - نمونه‌های تولید شده به صورت شرطی توسط مدل Conditional ScoreNet. (هر ردیف نشان‌دهنده تولید نمونه‌هایی برای یک کلاس خاص است؛ ردیف اول: عدد ۰، ردیف دوم: عدد ۱، ... تا ردیف دهم: عدد ۹)

در Figure 15 که در بالا قابل مشاهده است توانایی مدل در Conditioning به وضوح دیده می‌شود. برخلاف مدل قبلی که اعداد را به صورت تصادفی تولید می‌کرد، در اینجا با تغییر لیبل ورودی (y)، مدل دقیقاً عدد متناظر با آن کلاس را تولید کرده است. همانطور که مشخص است، تمام تصاویر موجود در یک ردیف با وجود تفاوت‌های ظاهری در دست خط، همگی ویژگی‌های ساختاری آن عدد را حفظ کرده‌اند و همچنین هیچ‌گونه تداخل کلاسی مشاهده نمی‌شود که نشان‌دهنده اثربخشی مکانیزم ترکیب embedding ها در معماری شبکه است.

تحلیل مقایسه‌ای با بخش قبل:

با بررسی خروجی های مدل غیرشرطی بخش قبل با مدل شرطی در این بخش، تفاوت هایی قابل مشاهده هستند که در ادامه توضیح می دهیم:

کنترل پذیری مدل

در مدل پایه، ما صرفاً می‌توانستیم به مدل بگوییم یک عدد بساز. مدل هم به صورت تصادفی یکی از ارقام را انتخاب می‌کرد. اما در بخش دوم، با اضافه کردن لیبل‌ها، عملاً کنترل فرآیند را به دست گرفتیم. همانطور که در Figure 15 خروجی می‌بینیم، ما توانستیم به مدل دستور دهیم که در هر ردیف دقیقاً چه عددی تولید کند. این ویژگی باعث می‌شود مدل از حالت یک تولیدکننده تصادفی خارج شود.

حذف ابهام و شفافیت بیشتر

یکی دیگر از موارد جالب در نتایج مدل پایه این بود که گاهی اوقات تصاویری تولید می‌شدند که انگار ترکیبی از دو عدد بودند (مثلاً چیزی بین ۳ و ۸). دلیلش این است که سمپلر گاهی در فضای میان دو عدد گیر می‌کند. اما در مدل شرطی، این مشکل تقریباً از بین رفته است. وقتی به مدل می‌گوییم مثلاً عدد ۵ بساز، بردار embedding کلاس مثل یک راهنما عمل می‌کند و سمپلر را دقیقاً به سمت مرکز داده‌های عدد ۵ هل می‌دهد. به همین خاطر، تصاویر خروجی در مدل شرطی معمولاً تمیزتر هستند و لبه‌های مشخص‌تری دارند، چون مدل دچار سردرگمی بین دو عدد نمی‌شود.

پایداری در تولید

در مدل بدون شرط، ممکن بود در یک Batch شانزده تایی، مثلاً اصلاً عدد ۲ تولید نشود و پنج بار عدد ۱ تولید شود و در واقع مدل در تولید توازن نداشته باشد. اما مدل شرطی این تضمین را می‌دهد که تنوع خروجی دقیقاً مطابق خواست ما باشد. به طور کلی، اضافه کردن شرط به مدل NCSN نه تنها قابلیت تولید هدفمند را به ما می‌دهد، بلکه باعث می‌شود کیفیت بصری تصاویر هم بهتر شود، چون فضای جستجوی مدل محدودتر و مشخص‌تر شده است.