



به نام خدا



دانشگاه تهران
دانشکده مهندسی برق و کامپیوتر
مدل‌های مولد عمیق

تمرین اول

نام و نام خانوادگی	سید نوید هاشمی
شماره دانشجویی	810101549
تاریخ ارسال گزارش	1404/8/10

فهرست


4.....	سؤال اول
4.....	بخش اول
4.....	زیربخش اول
4.....	زیربخش دوم
4.....	زیربخش سوم
5.....	بخش دوم
5.....	زیربخش اول
5.....	زیربخش دوم
5.....	زیربخش سوم
5.....	زیربخش چهارم
6.....	زیربخش پنجم
6.....	زیربخش ششم
7.....	بخش سوم
7.....	زیربخش اول
7.....	زیربخش دوم
7.....	زیربخش سوم
8.....	بخش چهارم
9.....	سوال دوم
9.....	بخش اول
9.....	زیربخش اول
10.....	زیربخش دوم

12.....	زیربخش سوم
13.....	زیربخش چهارم
14.....	زیربخش پنجم
15.....	زیربخش ششم
17.....	زیربخش هفتم
19.....	زیربخش هشتم
21.....	بخش دوم
21.....	زیربخش اول
22.....	زیربخش دوم
23.....	زیربخش سوم
24.....	مراجع

سؤال اول

بخش اول

زیربخش اول



زیربخش دوم

$$P(M, I, T, S, F, D) = P(M)P(I | M, S)P(T | I, F)P(S)P(F)P(D | I, T)$$

زیربخش سوم

a. نادرست - مسیر $F \rightarrow T \rightarrow D$ بلاک نشده است.

b. درست - مسیرهای $S \rightarrow I \rightarrow T \rightarrow D$ و $S \rightarrow I \rightarrow D$ بلاک شده اند.

c. درست - دو تا مسیر داریم که در واقع از نوع v-structure هستند و چون نود میانی داده

نشده مسیرها بلاک شده اند. (مسیرهای $M \rightarrow I \rightarrow T \leftarrow F$ و $M \rightarrow I \rightarrow D \leftarrow T \leftarrow F$)

d. نادرست - مسیر $M \rightarrow I \rightarrow T \leftarrow F$ از نوع v-structure است ولی نود میانی (T) داده شده، پس این مسیر بلاک نشده پس دو متغیر M, F در این شرایط مستقل نیستند.

e. درست - در مسیر $M \rightarrow I \rightarrow T$ متغیر I داده شده است پس مسیر بلاک شده است، همچنین در مسیر $M \rightarrow I \rightarrow D \leftarrow T$ متغیر D داده نشده که چون این مسیر v-structure است یعنی مسیر بلاک شده است.

بخش دوم

زیربخش اول

$$P(C, O, A, S, T, B, M) = P(C)P(O)P(A)P(S | O)P(T | O, A)P(B | S)P(M | B, T, A)$$

زیربخش دوم

$$MB(T) = \{O, A, M, B\}$$

زیربخش سوم

خیر - در گراف بی‌زی داریم $O \perp A$ ولی در این گراف بین O, A یال داریم پس در واقع این دو متغیر مستقل از هم نیستند؛ این مثال نقض تاییدی بر این است که این گراف، Perfect I-Map مربوط به گراف بی‌زی نیست.

زیربخش چهارم

خیر - زیرا با تعریف chordal همخوانی ندارد؛ در واقع حلقه S, O, T, B حلقه ای با طول 4 است ولی هیچ وترى ندارد، پس این گراف chordal نیست.

زیربخش پنجم

$$P(C, O, A, S, T, B, M) = \frac{1}{Z}$$

$$P(C, O, A, S, T, B, M) = \frac{1}{Z} \phi_1(C) \phi_2(T, A, M) \phi_3(T, O, A) \phi_4(T, B, M) \phi_5(B, S) \phi_6(S, O)$$

زیربخش ششم

عبارت اول

این عبارت درست است، اگر بخواهیم توزیع مشترک را روی سایر متغیرها حساب کنیم، باید از توزیع مشترک روی متغیر C انتگرال بگیریم (یا اگر گسسته بود روی مقادیر مختلف آن جمع بزنیم). از آنجا که در توزیع مشترک، متغیر C تنها در ترم $P(C)$ وجود دارد، بقیه ترمها نسبت به C ثابت اند و از زیر انتگرال خارج می شوند، و خواهیم داشت:

$$P(O, A, S, T, B, M) = P(O)P(A)P(S | O)P(T | O, A)P(B | S)P(M | B, T, A) \int P(C) dc$$

از آنجا که $\int P(C) dc = 1$ است، فقط کافیه فاکتور $P(C)$ را حذف کنیم.

عبارت دوم

مانند قسمت قبل، برای حذف C، باید از توزیع مشترک روی آن انتگرال بگیریم. از آنجا که در گراف مارکوف داده شده متغیر C ایزوله است، فاکتور پتانسیل آن $\phi_1(C)$ در هیچ فاکتور دیگری شریک نیست پس وقتی انتگرال می گیریم، ترمهای دیگر از زیر انتگرال خارج می شوند. تفاوت این قسمت با حالت قبلی این است که اینجا دیگر $\phi_1(C)$ توزیع احتمال نیست پس برای همین صورت سوال گفته فرض کنیم حال انتگرال آن روی C برابر با یک می شود.

علاوه بر آن، Z نیز به C وابسته است:

$$Z = \int_{C, O, \dots, M} \phi_1(C) \times \prod_{k \neq C} \phi_k(D_k) dC dO \dots dM$$

انتگرال ها را جدا می کنیم:

$$Z = \left[\int \phi_1(C) dC \right] \times \left[\int_{O, \dots, M} \prod_{k \neq C} \phi_k(D_k) dO \dots dM \right]$$

حال اگر شرط سوال را اعمال کنیم خواهیم داشت:

$$Z = 1 \times \left[\int_{O, \dots, M} \prod_{k \neq C} \phi_k(D_k) dO \dots dM \right]$$

عبارت داخل براکت، دقیقاً همان تابع پارتیشن جدید برای گرافی است که دیگر C را ندارد؛ پس این عبارت هم درست است.

بخش سوم

زیربخش اول

$$P(A, B, C, D, E, F, G) = \frac{1}{Z} \phi_1(A, B, C) \phi_2(B, D, C) \phi_3(D, C, F) \phi_4(B, E) \phi_5(E, F) \phi_6(E, G)$$

زیربخش دوم

- a. نادرست - چون بین آنها مسیر وجود دارد. $(A - B - E - G)$.
- b. نادرست - چون بین آنها مسیر وجود دارد. $(A - B - E - F)$.
- c. درست - چون دیگر مسیری بینشان وجود نخواهد داشت.
- d. درست - چون با داشتن B, C دیگر مسیری بین A, E وجود نخواهد داشت.

زیربخش سوم

برای اینکه انتگرال توزیع احتمال مشترک روی همه متغیر ها برابر با 1 شود، اگر تابع پتانسیل مذکور 5 برابر شود، Z نیز باید 5 برابر شود در نتیجه تغییری که حاصل می شود این است که خواهیم

$$\text{داشت: } Z_{\text{new}} = \frac{1}{5} Z$$

$$L(\theta) = E_{q(z)}[\log p(x, z)] - E_{q(z)}[\log q(z)]$$

$$p(x, z) = p(x|z)p(z) = (ze^{-zx})(e^{-z})$$

$$p(x, z) = ze^{-z(x+1)}$$

$$\log p(x, z) = \log(z) - z(x+1)$$

$$E_q[\log p(x, z)] = E_q[\log(z)] - (x+1)E_q[z]$$

$$E_q[\log p(x, z)] = E_q[\log(z)] - \frac{2(x+1)}{\theta}$$

$$\log q(z) = \log(\theta^2 ze^{-\theta z}) \log q(z) = 2 \log(\theta) + \log(z) - \theta z$$

$$E_q[\log q(z)] = 2 \log(\theta) + E_q[\log(z)] - \theta E_q[z]$$

$$E_q[\log q(z)] = 2 \log(\theta) + E_q[\log(z)] - \theta \left(\frac{2}{\theta}\right)$$

$$E_q[\log q(z)] = 2 \log(\theta) + E_q[\log(z)] - 2$$

$$L(\theta) = \left(E_q[\log(z)] - \frac{2(x+1)}{\theta} \right) - (2 \log(\theta) + E_q[\log(z)] - 2)$$

$$L(\theta) = -\frac{2(x+1)}{\theta} - 2 \log(\theta) + 2$$

$$\frac{dL}{d\theta} = \frac{d}{d\theta} [-2(x+1)\theta^{-1} - 2 \log(\theta) + 2]$$

$$\frac{dL}{d\theta} = \frac{2(x+1)}{\theta^2} - \frac{2}{\theta} \frac{2(x+1)}{\theta^2} - \frac{2}{\theta} = 0$$

$$\frac{2(x+1)}{\theta^2} = \frac{2}{\theta}$$

$$2(x+1) = 2\theta$$

$$\theta = x+1$$

سوال دوم

بخش اول

زیربخش اول

برای محاسبه‌ی درست‌نمایی یک نمونه داده‌ی منفرد $P_\theta(x)$ ، باید تمام مقادیر ممکن متغیر پنهان Z که می‌توانستند آن x را تولید کنند، در نظر بگیریم. این کار مستلزم حاشیه‌ای کردن متغیر Z از طریق یک انتگرال بر روی کل فضای پنهان است:

$$P_\theta(x) = \int_z P_\theta(x, z) dz = \int_z P(z)P_\theta(x|z) dz$$

محاسبه‌ی این انتگرال در فضاهای چندبعدی، هم به صورت تحلیلی و هم به صورت عددی، عملاً غیرممکن است.

برای غلبه بر مشکل عدم حل‌پذیری، VAE یک رویکرد تقریبی را معرفی می‌کند. از آنجایی که محاسبه‌ی توزیع پسین واقعی $P_\theta(z|x)$ ممکن نیست، ما یک توزیع ساده‌تر و قابل محاسبه، با نام $q_\phi(z|x)$ ، را برای تقریب آن معرفی می‌کنیم. این توزیع توسط یک شبکه‌ی عصبی دیگر به نام Encoder با پارامترهای ϕ مدل‌سازی می‌شود. هدف این است که $q_\phi(z|x)$ را تا حد امکان به $P_\theta(z|x)$ نزدیک کنیم.

همانطور که در اسلاید های درس گفته شد، با انجام یکسری اعمال ریاضی به رابطه زیر می‌رسیم:

$$\log P_\theta(x) = KL(q_\phi(z|x) || L(\theta, \phi; x))$$

در این رابطه، $L(\theta, \phi; x)$ عبارتی جدید به نام (Evidence Lower Bound - ELBO) است. از آنجایی که واگرایی KL همیشه مقداری نامنفی است، این تساوی نشان می‌دهد که ELBO همواره یک کران پایین برای لگاریتم درست‌نمایی واقعی است:

$$\log P_\theta(x) \geq L(\theta, \phi; x)$$

این رابطه، کلید حل مشکل است. ما نمی‌توانیم $\log P_\theta(x)$ را مستقیماً بیشینه کنیم، اما می‌توانیم کران پایین آن، یعنی ELBO، را بیشینه کنیم. با بالا بردن این کران پایین، به طور غیرمستقیم خود لگاریتم درست‌نمایی را نیز به سمت بالا سوق می‌دهیم. و برخلاف $\log P_\theta(x)$ در عمل قابل محاسبه است.

حال به بخش دوم سوال شما می‌پردازیم، با انجام یکسری اعمال ریاضی به این رابطه می‌رسیم که دقیقاً همان تابع هزینه داده شده است:

$$L(\theta, \varphi; x) = E_{q_{\varphi}(z|x)}[p(x|z)] - D_{KL}[q_{\varphi}(z|x) || p(z)]$$

جمله‌ی اول، $E_{q_{\varphi}(z|x)}[p(x|z)]$ ، امید ریاضی لگاریتم درست‌نمایی بازسازی داده است. به زبان ساده‌تر، این جمله به این پرسش پاسخ می‌دهد: «اگر ورودی x را با رمزگذار به یک توزیع در فضای پنهان نگاشت کنیم، یک کد z از آن نمونه‌برداری کنیم و به رمزگشا بدهیم، چقدر محتمل است که رمزگشا بتواند همان x اصلی را بازسازی کند؟»

بیشینه کردن این عبارت، مدل را وادار می‌کند تا یک جفت رمزگذار-رمزگشا بسازد که در فرآیند Auto-encoding مهارت بالایی داشته باشد و اطلاعات ورودی را به خوبی حفظ کند. به همین دلیل به آن، خطای بازسازی (Reconstruction Loss) می‌گویند.

جمله‌ی دوم، $D_{KL}[q_{\varphi}(z|x) || p(z)]$ ، یک واگرایی KL بین توزیع خروجی رمزگذار برای یک داده‌ی خاص $q_{\varphi}(z|x)$ و توزیع پیشین ثابت $p(z)$ است. این جمله نقش یک تنظیم‌کننده (Regularizer) را ایفا می‌کند. این بخش، مدل را جریمه می‌کند اگر توزیع کدهای تولید شده توسط رمزگذار برای داده‌های مختلف، بیش از حد از توزیع پیشین (که معمولاً نرمال استاندارد است) فاصله بگیرد.

اهمیت این جمله برای قابلیت تولید (generation) مدل حیاتی است. بدون این تنظیم‌کننده، VAE به یک خودرمزگذار معمولی تبدیل می‌شود. در آن حالت، رمزگذار آزاد است تا برای هر ورودی x یک کد پنهان منحصر به فرد و دور از بقیه در فضای پنهان پیدا کند تا بازسازی را به بهترین شکل ممکن انجام دهد. این کار منجر به یک فضای پنهان گسسته، تکه‌تکه و پر از حفره می‌شود که برای تولید داده‌های جدید بی‌فایده است.

جمله‌ی KL تمام توزیع‌های خروجی encoder را مجبور می‌کند تا در اطراف مبدأ مختصات (مرکز توزیع پیشین) جمع شوند، با یکدیگر همپوشانی داشته باشند و فضای پنهان را به شکلی منظم و پیوسته پر کنند. این پیوستگی، کلید اصلی تولید است. این ساختار تضمین می‌کند که اگر ما یک نقطه‌ی جدید z را مستقیماً از توزیع پیشین $p(z)$ نمونه‌برداری کنیم، آن نقطه در ناحیه‌ای از فضای پنهان قرار می‌گیرد که decoder آن را می‌فهمد و می‌تواند آن را به یک نمونه داده‌ی جدید و قابل قبول x' نگاشت کند.

زیربخش دوم

دادگان dsprites یک مجموعه داده استاندارد و پرکاربرد در حوزه یادگیری ماشین، به‌ویژه برای ارزیابی مدل‌های یادگیری بدون نظارت (Unsupervised Learning) است.

هدف اصلی این دادگان، آزمایش توانایی مدل‌ها در یادگیری بازنمایی‌های گسسته (Disentangled Representations) است. به عبارت ساده‌تر، از این دادگان استفاده می‌شود تا مشخص شود آیا یک مدل (مانند مدل‌های VAE یا Autoencoder) می‌تواند عوامل یا ویژگی‌های اساسی و مستقل سازنده‌ی داده‌ها را به درستی از هم تفکیک کند و یاد بگیرد یا خیر.

این دادگان شامل ۷۳۷,۲۸۰ تصویر سیاه‌وسفید با ابعاد ۶۴x۶۴ پیکسل است. تصاویر به صورت الگوریتمی (procedurally generated) ساخته شده‌اند و شامل اشکال دوبعدی ساده (sprites) هستند. علاوه بر آن، هر تصویر بر اساس ۶ عامل (فاکتور) مستقل و مشخص ساخته شده است. تمام ترکیبات ممکن از این ۶ عامل در دادگان وجود دارد.

این 6 عامل سازنده عبارتند از:

1. رنگ (Color) - 1 مقدار (همیشه سفید)
2. شکل (Shape) - 3 مقدار (مربع، بیضی، قلب)
3. مقیاس (Scale) - 6 مقدار
4. چرخش (Orientation) - 400 مقدار
5. موقعیت X (Position X) - 32 مقدار
6. موقعیت Y (Position Y) - 32 مقدار

به طور خلاصه، dsprites ابزاری ایده‌آل برای سنجش این موضوع است که آیا یک مدل هوش مصنوعی می‌تواند به طور خودکار بفهمد که یک تصویر از شکل، اندازه، موقعیت و چرخش تشکیل شده است، بدون اینکه این اطلاعات به صورت مستقیم به آن آموزش داده شده باشد.




Figure 1 - چند نمونه از تصاویر موجود در دیتاست (dsprites)

زیربخش سوم

ترفند بازپارامترسازی (Reparameterization Trick)

ایده اصلی این ترفند، جدا کردن بخش تصادفی از بخش پارامتری (قابل یادگیری) است. ما این کار را با تغییر فرمول محاسبه Z انجام می‌دهیم؛ به جای اینکه Z را مستقیماً از توزیع $\mathcal{N}(\mu, \sigma^2)$ نمونه‌گیری کنیم، یک نویز استاندارد تعریف می‌کنیم، در واقع ابتدا یک متغیر تصادفی ϵ (اپسیلون) از یک توزیع نرمال استاندارد (با میانگین ۰ و واریانس ۱) نمونه‌گیری می‌کنیم. این گره ϵ هیچ پارامتر قابل یادگیری ندارد و کاملاً تصادفی است $\epsilon \sim \mathcal{N}(0, 1)$.

حالا Z را با استفاده μ, σ, ϵ از طریق یک فرمول ریاضی ساده و مشتق‌پذیر محاسبه می‌کنیم:

$$z = \mu + \sigma \cdot \epsilon$$

با این ترفند، ما گره تصادفی ϵ را از مسیر اصلی شبکه خارج کرده و آن را به عنوان یک ورودی (در کنار ورودی اصلی x) در نظر می‌گیریم؛ encoder همچنان μ و σ را یاد می‌گیرد، عملیات نمونه‌گیری ϵ خارج از مسیر گرادیان است و همچنین z اکنون یک تابع قطعی و مشتق‌پذیر از μ و σ است. حالا در زمان پس‌انتشار خطا، گرادیان‌ها می‌توانند به راحتی از z عبور کرده و به μ و σ (و در نتیجه به لایه‌های encoder) برسند، زیرا:

- مشتق z نسبت به μ برابر با 1 است.

- مشتق z نسبت به σ برابر با ϵ است.

به این ترتیب، زنجیره گرادیان حفظ می‌شود و کل شبکه (encoder + decoder) می‌تواند به صورت سرتاسری آموزش ببیند.

زیربخش چهارم




Figure 2 - روند تغییرات تابع هزینه کل (Negative ELBO)، هزینه بازسازی (BCE) و واگرایی KL در طول ۵۰ اپیک آموزش مدل VAE بر روی داده‌گان dsprites.




Figure 3 - مقایسه ۸ نمونه تصادفی از دادگان (ردیف بالا Original) با نسخه‌های بازسازی‌شده توسط مدل VAE آموزش‌دیده (ردیف پایین Reconstructed) جهت ارزیابی کیفی عملکرد مدل.

همانطور که در Figure 2, 3 مشاهده می‌شود، عملکرد مدل VAE در بازسازی ۸ نمونه تصادفی از دادگان، نکات زیر را نشان می‌دهد:

مدل به وضوح توانسته است عوامل اصلی و سطح بالای داده‌ها را به درستی یاد بگیرد و بازسازی کند. عواملی مانند شکل (Shape)، موقعیت (Position) و مقیاس (Scale) در تمام ۸ نمونه به درستی از تصویر اصلی به تصویر بازسازی‌شده منتقل شده‌اند.

مهم‌ترین نکته‌ای که در تصاویر بازسازی‌شده جلب توجه می‌کند، تار بودن نسبی (blurry) لبه‌های اشکال در مقایسه با تصاویر اصلی است. تصاویر اصلی دارای لبه‌های کاملاً تیز و مشخص (binary) هستند، در حالی که خروجی مدل (که از یک لایه Sigmoid می‌آید) لبه‌های نرم‌تر و کمی محو شده دارد. این پدیده یکی از مشخصه‌های معروف و مورد انتظار در مدل‌های VAE استاندارد است که در واقع از دو بخش نشأت می‌گیرد:

- **تابع هزینه بازسازی:** این تابع هزینه، مدل را تشویق می‌کند تا میانگین پیکسل‌ها را یاد بگیرد (خروجی آن یک احتمال بین ۰ و ۱ است) و نه یک خروجی قطعی ۰ یا ۱. این امر به طور طبیعی منجر به لبه‌های خاکستری به جای سیاه/سفید مطلق می‌شود.

- **KL: واگرایی KL**، فضای نهان را مجبور می‌کند که نویزی و پیوسته باشد. decoder باید یاد بگیرد که از این فضای نهان کمی آشفته، یک تصویر واضح بسازد که این کار سخت است و اغلب به بازسازی‌های میانگین و در نتیجه تار منجر می‌شود.

نتیجه‌گیری کلی: مدل VAE با موفقیت ساختار کلی و ویژگی‌های اساسی دادگان را درک کرده و یاد گرفته است، اما همانطور که انتظار می‌رفت، در بازسازی جزئیات با فرکانس بالا (لبه‌های تیز) ضعف نشان می‌دهد.

زیربخش پنجم

بهبود اصلی مدل β -VAE نسبت به نسخه استاندارد، توانایی آن در یادگیری یک فضای نهان گسسته‌تر است.

همانطور که در رابطه $E_{q_\phi(z|x)}[p(x|z)] - \beta D_{KL}[q_\phi(z|x) || p(z)]$ مشخص است، با اضافه شدن ضریب β (که معمولاً $\beta < 1$ است) به ترم واگرایی D_{KL} ، در عمل جریمه یا فشار بیشتری به مدل اعمال می‌شود تا فضای نهان $q(z|x)$ را به توزیع پیشین $p(z)$ (که معمولاً یک توزیع نرمال استاندارد است) نزدیک کند.

این فشار مضاعف، مدل را مجبور می‌کند که راه‌های بهینه‌تری برای فشرده‌سازی اطلاعات پیدا کند و هر بعد از فضای نهان z را تشویق می‌کند تا به صورت مستقل، یکی از عوامل اساسی و واقعی تغییر در داده‌ها (مانند شکل، اندازه یا موقعیت در داده‌گان dsprites) را نمایندگی کند. در واقع، مدل β -VAE برای افزایش گسستگی و قابل تفسیر بودن فضای نهان، اولویت و ضریب بیشتری به «کیفیت بازسازی» می‌دهد، که اغلب منجر به فضاهای نهان معنادارتر، اما بازسازی‌های کمی تارتر می‌شود.

زیربخش ششم




Figure 4 - مقایسه روند هزینه کل (Negative ELBO) در طول آموزش برای مدل β -VAE با ضریب $\beta=4.0$ (آبی) و $\beta=20.0$ (نارنجی).




Figure 5 - مقایسه روند هزینه بازسازی (BCE)؛ مدل با $\beta = 4.0$ (آبی) به خطای بازسازی به مراتب کمتری نسبت به مدل با $\beta = 20.0$ (نارنجی) دست یافته است.




Figure 6 - مقایسه روند واگرایی KL (بدون اعمال ضریب β)؛ مدل با $\beta = 20.0$ (نارنجی) ترم KL را در مقدار کمتری (حدود ۵.۸) نسبت به مدل با $\beta = 4.0$ (آبی) نگه داشته است. (حدود ۱۵.۸)

این سه نمودار به وضوح توازن (Trade-off) کلیدی در مدل β -VAE را نشان می‌دهند:

1. تحلیل هزینه بازسازی

مدل با $\beta = 4.0$ (آبی) به خطای بازسازی بسیار کمتری (حدود ۴۰) دست یافته است. همچنین مدل با $\beta = 20.0$ (نارنجی) خطای بازسازی بسیار بالاتری دارد. علت آن این است که ضریب β مستقیماً ترم KL را جریمه می‌کند. وقتی β بزرگ است (۲۰.۰)، مدل

مجبور می‌شود که گسستگی (Disentanglement) و نظم فضای نهان را به کیفیت بازسازی ترجیح دهد. در نتیجه، برای منظم نگه داشتن فضای نهان، از کیفیت بازسازی تصویر صرف‌نظر می‌کند و خطای BCE بالا می‌رود.

2. تحلیل KL

مدل با $\beta = 20.0$ (نارنجی) مقدار D_{KL} را کمتر نگه داشته است، درحالی که مدل با $\beta = 4.0$ (آبی) اجازه داده است D_{KL} بیشتر شود. در واقع از آنجا که جریمه KL برای مدل با $\beta = 20.0$ بسیار سنگین است، مدل به شدت تلاش می‌کند تا D_{KL} را تا حد امکان پایین نگه دارد اما مدل با $\beta = 4.0$ جریمه کمتری دارد پس آزادی بیشتری دارد که D_{KL} را افزایش دهد تا بتواند در عوض بازسازی بهتری (خطای BCE کمتر) ارائه دهد.

3. تحلیل هزینه کل

هزینه کل برای مدل $\beta = 20.0$ (نارنجی) به طور قابل توجهی بالاتر از $\beta = 4.0$ (آبی) است. این یک نتیجه مستقیم ریاضی است. هزینه کل برابر است با:

$$Loss = BCE + (\beta \times D_{KL})$$

در واقع بالاتر بودن هزینه کل مدل با $\beta = 20.0$ به معنای بدتر بودن مدل نیست؛ بلکه نشان می‌دهد که تابع هدف آن، وزن بسیار بیشتری به منظم‌سازی فضای نهان (ترم KL) داده است.

زیربخش هفتم

توضیح معیار MIG (Mutual Information Gap)

معیار MIG [1] یکی از روش‌های استاندارد برای ارزیابی کمی گسستگی (Disentanglement) بازنمایی‌های نهان در مدل‌های مولد است. هدف یک بازنمایی گسسته این است که هر بعد از فضای نهان z تنها به یکی از عوامل اساسی و مستقل سازنده داده v (مانند شکل، مقیاس، چرخش و... در این دیتاست) حساس باشد و به سایر عوامل حساس نباشد.

معیار MIG این ویژگی را با استفاده از اطلاعات متقابل (Mutual Information) اندازه‌گیری می‌کند. اطلاعات متقابل $I(z_i; v_k)$ ، میزان اطلاعات مشترک بین بعد i ام فضای نهان (z_i) و عامل k ام داده (v_k) را محاسبه می‌کند.

برای محاسبه نمره MIG، به ازای هر عامل واقعی v_k (مثلاً Scale)

۱. بعد نهانی (z_i) که بیشترین اطلاعات متقابل را با v_k دارد، پیدا می‌شود.

۲. بعد نهانی (z_j) که دومین بیشترین اطلاعات متقابل را با v_k دارد، پیدا می‌شود.

۳. شکاف (Gap) بین این دو مقدار محاسبه و بر آنتروپی عامل $H(v_k)$ نرمال سازی می شود:

$$Gap_k = \frac{I(z_i; v_k) - I(z_j; v_k)}{H(v_k)}$$

نمره نهایی MIG برای مدل، میانگین این شکاف ها به ازای تمام عوامل واقعی داده است. شکاف بزرگتر (نمره MIG بالاتر) نشان می دهد که یک بعد نهان به طور واضح بر روی یک عامل خاص متخصص شده و ابعاد دیگر در آن دخالت نمی کنند، که این نشان دهنده گسستگی مطلوب است.

تحلیل نتایج نهایی MIG

--- Final MIG Results Comparison ---

VAE (Beta=1)	: 0.0241
b-VAE (Beta=4.0)	: 0.0250
b-VAE (Beta=20.0)	: 0.0836

Figure 7 - مقایسه نمره نهایی گسستگی (MIG) برای سه مدل آموزش دیده. نتایج نشان می دهد که افزایش ضریب β به $\beta = 20.0$ منجر به افزایش چشمگیر نمره MIG و در نتیجه، گسسته تر شدن فضای نهان شده است.

نتایج به دست آمده به وضوح، تأثیر مستقیم افزایش ضریب β بر گسستگی (Disentanglement) فضای نهان را تأیید می کنند:

1. مقایسه $\text{VAE} (\beta=1)$ و $\text{b-VAE} (\beta=4.0)$

مدل VAE استاندارد (نمره 0.0241) و مدل β -VAE با ضریب پایین (نمره 0.0250)، هر دو نمرات بسیار پایینی کسب کردند. این اختلاف ناچیز نشان می دهد که فشار ناشی از $\beta = 4.0$ به اندازه ای نبوده که استراتژی مدل را به طور قابل توجهی تغییر دهد. در هر دو حالت، مدل همچنان کیفیت بازسازی را به گسستگی فضای نهان ترجیح داده است.

2. عملکرد $\text{b-VAE} (\beta=20.0)$

مدل β -VAE با ضریب بالا، نمره 0.0836 را کسب کرد که به طور قابل توجهی (بیش از ۳ برابر) بهتر از دو مدل دیگر است. این جهش ناگهانی نشان می دهد که تنها زمانی که جریمه ی ترم D_{KL} به اندازه ی کافی سنگین باشد ($\beta = 20.0$)، مدل مجبور می شود که اطلاعات را به صورت بهینه تر و مستقل تری در ابعاد نهان توزیع کند.

این نتایج به طور کمی ثابت می کنند که افزایش β مستقیماً به گسسته تر شدن فضای نهان کمک می کند. این دقیقاً با مشاهدات کیفی ما (تارتر شدن تصاویر بازسازی شده در $\beta = 20.0$) و تحلیل نمودارهای هزینه (افزایش خطای بازسازی و کاهش خطای KL در $\beta = 20.0$) همخوانی دارد. مدل با β بالا، کیفیت بازسازی را فدا می کند تا به یک بازنمایی نهان منظم تر و گسسته تر دست یابد.

زیربخش هشتم




Figure 8- تحلیل PCA فضای نهان، رنگ آمیزی شده بر اساس فاکتورهای (نمودار سمت چپ) Shape (شکل) و (نمودار سمت راست) Scale (مقیاس). همانطور که مشاهده می شود، رنگ ها در هر دو نمودار به صورت پراکنده و بدون ساختار مشخصی توزیع شده اند، که نشان می دهد مؤلفه های اصلی ۱ و ۲، همبستگی معناداری با این دو فاکتور ندارند.




Figure 9- تحلیل PCA فضای نهان، رنگ آمیزی شده بر اساس فاکتورهای (نمودار سمت چپ) Position X و (نمودار سمت راست) Position Y. در این دو نمودار، گرادیان های رنگی واضحی مشاهده می شود که نشان دهنده همبستگی شدید مؤلفه اصلی اول (PC1) با «موقعیت افقی» و مؤلفه اصلی دوم (PC2) با «موقعیت عمودی» است.

نمودارهای فوق، نتیجه ی اعمال تحلیل مؤلفه های اصلی (PCA) بر روی بازنمایی های نهان (μ) استخراج شده از مدل β -VAE ($\beta=20.0$) را نشان می دهند. فضای نهان ۳۲ بعدی مدل به دو مؤلفه اصلی (PC1, PC2) که بیشترین واریانس داده ها را توصیف می کنند، کاهش یافته است. هر نقطه

در نمودارها نماینده یک تصویر است و بر اساس یکی از چهار فاکتور واقعی (شکل، مقیاس، موقعیت X و موقعیت Y) رنگ آمیزی شده است.

- ساختار فضای نهان

برخلاف یک ابر نقطه تصادفی و بی شکل (blob)، فضای نهان کاهش یافته دارای یک ساختار هندسی کاملاً مشخص (شبيه به یک قوس) است. این نشان می دهد که مدل، داده ها را به شیوه ای منظم و معنادار سازماندهی کرده است.

- فاکتورهای Shape, Scale

در نمودار های موجود در Figure 7، رنگ های مربوط به «شکل» و «مقیاس» به صورت پراکنده و بدون هیچ الگوی مشخصی در فضا پخش شده اند. این بدان معناست که دو مؤلفه اصلی واریانس در فضای نهان، همبستگی خاصی با این دو فاکتور ندارند.

- فاکتور های Position X, Position Y

در دو نمودار های موجود در Figure 8، یک الگوی کاملاً واضح و پیوسته مشاهده می شود: نمودار *Position X*: یک گرادیان رنگی یکنواخت در امتداد مؤلفه اصلی اول (محور افقی) وجود دارد. این نشان می دهد که PC1 مستقیماً فاکتور «موقعیت افقی» را کدگذاری کرده است.

نمودار *Position Y*: گرادیان رنگی مشابهی در امتداد مؤلفه اصلی دوم (محور عمودی) دیده می شود. این نشان می دهد که PC2 مستقیماً فاکتور «موقعیت عمودی» را کدگذاری کرده است.

تحلیل PCA به صورت بصری نشان می دهد که مدل β -VAE ($\beta = 20.0$) موفق شده است دو فاکتوری که بیشترین واریانس را در داده ها دارند (Position X, Position Y)، شناسایی کرده و آن ها را به طور مستقل بر روی دو مؤلفه اصلی فضای نهان خود نگاشت دهد.

در رابطه با بخش دوم سوال نیز باید بگویم این نتایج کاملاً با نتایج MIG (نمره 0.0836) همخوانی دارند و آن را به صورت بصری تأیید می کنند.

نمره بالای MIG برای مدل $\beta=20.0$ به صورت کمی نشان داد که این مدل دارای «گسستگی» بالایی است؛ یعنی ابعاد نهان z_i آن موفق شده اند به صورت مستقل، فاکتورهای واقعی داده ها v_k را نمایندگی کنند.

نمودارهای PCA این ادعا را به صورت کیفی و بصری ثابت می کنند. در یک مدل گسسته، انتظار می رود جهتهایی که بیشترین واریانس را در فضای نهان دارند (PC1, PC2) با فاکتورهایی که بیشترین واریانس را در داده های واقعی دارند (Position X, Position Y) منطبق باشند. نمودارهای ما دقیقاً همین انطباق کامل را نشان می دهند. بنابراین، ساختار واضحی که در نمودارهای PCA

مشاهده می‌شود، نتیجه مستقیم گسستگی موفق است که قبلاً توسط نمره بالای MIG اندازه‌گیری شده بود.

بخش دوم

زیربخش اول

تفاوت مدل VQ-VAE با مدل پایه (VAE)

تفاوت بنیادین مدل VQ-VAE (Vector Quantised-Variational AutoEncoder) با VAE استاندارد، در ماهیت فضای نهان (latent space) آن است. در VAE استاندارد، فضای نهان پیوسته (continuous) است. encoder پارامترهای یک توزیع (معمولاً گاوسی) را تولید می‌کند و یک نمونه z از این توزیع به decoder داده می‌شود. اما در VQ-VAE، فضای نهان گسسته (discrete) است. encoder یک بردار تولید می‌کند، اما این بردار مستقیماً به decoder داده نمی‌شود، بلکه با مجموعه‌ای محدود از بردارهای از پیش تعریف‌شده در یک دفترچه کد (Codebook) جایگزین می‌شود.

در واقع گسسته‌سازی در این مدل از طریق فرآیندی به نام کوانتیزاسیون برداری انجام می‌شود که شامل مراحل زیر است؛

• تعریف Codebook

یک فضای نهان گسسته و مشترک به نام E (که به آن Codebook یا Embedding Space گفته می‌شود) تعریف می‌شود. این فضا حاوی K بردار (Embedding) قابل یادگیری است.

$$(E = \{e_1, e_2, \dots, e_k\})$$

• خروجی encoder

encoder تصویر ورودی x را به یک بردار پیوسته $z_e(x)$ نگاشت می‌کند.

• کوانتیزاسیون

بردار $z_e(x)$ با تمام K بردار موجود در Codebook مقایسه می‌شود و نزدیک‌ترین بردار (بر اساس فاصله اقلیدسی) انتخاب می‌شود.

$$z_q(x) = e_k \quad \text{where} \quad k = \operatorname{argmin}_j \|z_e(x) - e_j\|_2$$

• ورودی decoder

این بردار گسسته $z_q(x)$ (که کپی یکی از بردارهای Codebook است) به عنوان ورودی به decoder داده می‌شود تا تصویر را بازسازی کند.

این رویکرد گسسته دو مزیت عمده نسبت به VAE پایه دارد؛ مورد اول آنکه در VAE استاندارد، ترم D_{KL} گاهی باعث می‌شود که encoder نادیده گرفته شود و فضای نهان z هیچ اطلاعات مفیدی از ورودی x نداشته باشد، اما VQ-VAE این ترم را حذف می‌کند و با اجبار encoder به انتخاب یکی از کدهای گسسته، تضمین می‌کند که فضای نهان همیشه حاوی اطلاعات معنادار است. همچنین از آنجایی که decoder به جای یادگیری تابعی بر روی یک فضای پیوسته بی‌نهایت، تنها بر روی تعداد محدودی ($K = 512$) ورودی گسسته آموزش می‌بیند، می‌تواند برای هر ورودی، بازسازی‌های بسیار دقیق‌تر، واضح‌تر و با جزئیات بالاتری تولید کند. این امر مشکل اصلی VAE ها در تولید تصاویر تار را برطرف می‌سازد.

زیربخش دوم

در مقاله «VAE with a VampPrior»، نویسندگان یک راه‌حل برای بهبود استفاده از متغیرهای نهان و مقابله با پدیده فروپاشی پسین (Posterior Collapse) ارائه می‌دهند.

تفاوت اصلی این مدل در جایگزینی توزیع پیشین $p(z)$ (prior) است. در VAE استاندارد، $p(z)$ یک توزیع ثابت و ساده (معمولاً $\mathcal{N}(0, I)$) است. اما در VampPrior، توزیع $p(z)$ یک توزیع انعطاف‌پذیر، چندمدی (multi-modal) و قابل یادگیری است که به گونه‌ای آموزش می‌بیند تا تقریب بهتری از توزیع پسین تجمعی (aggregated posterior) واقعی داده‌ها، یعنی $E_{x \sim p(x)}[q(z|x)]$ باشد.

این توزیع پیشین جدید به صورت یک ترکیبی از توزیع‌های پسین (Mixture of Posteriors) مدل‌سازی می‌شود:

- مدل مجموعه ای از K (شبه ورودی/pseudo-inputs) به نام $u_1, u_2, \dots, u_K$ را به عنوان پارامترهای قابل یادگیری در نظر می‌گیرد.
- توزیع پیشین $p(z)$ به صورت یک توزیع ترکیبی یکنواخت از K مولفه تعریف می‌شود. هر مولفه، برابر با خروجی انکودر ($q(z|.)$ به ازای یکی از این شبه-ورودی‌ها است:

$$p(z) = \frac{1}{K} \sum_{k=1}^K q(z|u_k)$$

این K شبه-ورودی، همزمان با سایر پارامترهای شبکه (encoder, decoder) آموزش داده می‌شوند.

دلیل استفاده بهتر از متغیرهای نهان

مشکل اصلی VAE استاندارد، عدم تطابق بین توزیع پیشین ساده ($\mathcal{N}(0, I)$) و توزیع پسین تجمع پیچیده است. VampPrior با داشتن یک توزیع پیشین بسیار انعطاف‌پذیر (که ترکیبی از K توزیع است)، می‌تواند خود را به شکل پیچیده و چند-مدی داده‌ها تطبیق دهد.

همچنین از آنجایی که توزیع $p(z)$ حالا تقریب بسیار بهتری از $q(z)$ است، فشار روی ترم $D_{KL}(q(z|x) || p(z))$ کاهش می‌یابد. درواقع encoder دیگر مجبور نیست برای به حداقل رساندن این جریمه، اطلاعات ورودی x را نادیده بگیرد. در عوض، $q(z|x)$ می‌تواند اطلاعات معنادار x را در z کدگذاری کند و آن را به مولفه‌ی مناسب در توزیع ترکیبی $p(z)$ نگاشت دهد، که این دقیقاً به معنای استفاده بهتر از متغیرهای نهان است.

زیربخش سوم

توضیح مدل SC-VAE

SC-VAE مخفف (Sparse Coding-based Variational Autoencoder)، مدلی است که ساختار VAE استاندارد را با اصول کدگذاری تنک (Sparse Coding) ترکیب می‌کند.

تفاوت اصلی در توزیع پیشین (prior) فضای نهان z است. در VAE استاندارد، ما یک توزیع پیشین چگال (Dense)، معمولاً گوسی ($\mathcal{N}(0, I)$) داریم. اما در SC-VAE، ما یک توزیع پیشین تنک (Sparse Prior) (مانند توزیع لاپلاس یا Spike-and-Slab) را بر z اعمال می‌کنیم. این فرض بدان معناست که هر ورودی x می‌تواند به صورت ترکیبی خطی از تعداد کمی مولفه‌ی فعال (غیرصفر) از یک مجموعه‌ای از ویژگی‌های پایه، بازنمایی شود. در نتیجه، بردار نهان z که توسط encoder تولید می‌شود، یک بردار تنک خواهد بود (یعنی اکثر درایه‌های آن، صفر هستند).

نقش الگوریتم ISTA

پیدا کردن کد تنک بهینه z برای یک ورودی x (با فرض مشخص بودن مجموعه‌ای از ویژگی‌های پایه) یک مسئله بهینه‌سازی کلاسیک است. ISTA (Iterative Shrinkage-Thresholding Algorithm) یک الگوریتم تکرارشونده استاندارد برای حل این مسئله (به‌ویژه مسائل LASSO) است.

در مدل SC-VAE، به جای استفاده از یک encoder با معماری دلخواه (مانند CNN/MLP) معماری خود encoder بر اساس مراحل ریاضی الگوریتم ISTA طراحی شده است. این فرآیند که به آن باز کردن (Unrolling) الگوریتم گفته می‌شود، تکرارهای ISTA را به لایه‌های یک شبکه عصبی تبدیل می‌کند. پارامترهای این الگوریتم مانند (مجموعه‌ای ویژگی‌های پایه و پارامتر thresholding)

به جای ثابت بودن، به پارامترهای قابل یادگیری شبکه تبدیل می‌شوند (که به این ساختار LISTA یا Learned ISTA نیز گفته می‌شود).

بنابراین، نقش ISTA در این مدل، فراهم کردن یک ساختار محاسباتی برای encoder است که تضمین می‌کند خروجی آن (z) ذاتا تنک (sparse) باشد.

مزیت ها

بازنمایی‌های تنک دو مزیت عمده نسبت به بازنمایی‌های چگال در VAE پایه دارند:

- قابلیت تفسیر

این مهم ترین مزیت است. در یک بردار sparse، تنها چند بعد غیرصفر، مسئول بازسازی کل ورودی هستند. این باعث می شود هر بعد نهان z_i مجبور شود یک ویژگی یا مفهوم مشخص، معنادار و قابل فهم (مانند یک لبه، بافت یا جز خاصی از شیء) را یاد بگیرد.

- گسستگی و بهینه بودن

اجبار به sparse بودن، یک شکل بسیار قوی از Regularization است. در واقع این کار مدل را مجبور می کند تا ویژگی های در هم تنیده را از هم جدا کند و برای هر ورودی، تنها زیرمجموعه کوچکی از ابعاد نهان مرتبط را فعال کند که این کار منجر به بازنمایی کارآمدتر و گسسته تر (disentangled) خواهد شد.

مراجع

- Chen, R. T. Q., Li, X., Grosse, R. B., & Duvenaud, D. (2018). Isolating sources of disentanglement in variational autoencoders. In Advances in Neural Information Processing Systems (NeurIPS 2018).
- van den Oord, A., Vinyals, O., & Kavukcuoglu, K. (2017). Neural discrete representation learning. In Advances in Neural Information Processing Systems (NeurIPS 2017).

- Tomczak, J. M., & Welling, M. (2018). VAE with a VampPrior. In Proceedings of the Twenty-First International Conference on Artificial Intelligence and Statistics (AISTATS 2018) (Vol. 84, pp. 1214-1223). PMLR.
- Xiao, P., Qiu, P., Ha, S., Bani, A., Zhou, S., & Sotiras, A. (2024). Sparse Coding-based Variational Autoencoder with Learned ISTA (SC-VAE). Pattern Recognition, 161, Article 111187.